EVの駆動力制御のための 機械学習を用いた$\mu-\lambda$曲線推定を伴う最適スリップ率推定の基礎検討

堀越太智*，水口時和，郡司大輔，阮平明，永井栄寿，藤本博志（東京大学）
近藤謙太郎，安元宏平，北村毅史，鷹崎悠一，北条善久（東洋電機製造株式会社）

Basic Study on Optimal Slip Ratio Estimation with Machine Learning-Based Road Surface $\mu-\lambda$ Curve Identification for Electric Vehicle Driving Force Control

Taichi Horikoshi*, Tokikazu Mizuguchi, Daisuke Gunji, Binh-Minh Nguyen, Sakahisa Nagai, Hiroshi Fujimoto
(The University of Tokyo)
Kentaro Kondo, Kohei Yasumoto, Takeshi Kitamura, Yuichi Takasaki, Yoshihisa Hojo (TOYO DENKI SEIZO K.K.)

This paper proposes a method for estimating the optimal slip ratio for electric vehicle driving force control. The proposed method estimates the tire-road $\mu-\lambda$ curve in real time from partially observed data using a machine learning model and determines the optimal slip ratio from its peak. Offline evaluation using experimental data demonstrates its effectiveness.

キーワード：電気自動車，インホイールモータ，タイヤモデル推定，スリップ率，駆動力制御，ニューラルネットワーク
(electric vehicle，in-wheel motor，tire model estimation，slip ratio，driving force control，neural network)

1. 序論

電気自動車 (Electric Vehicle : EV) は，走行時に CO_2 を排出しないという特徴 [?] に加え，電動モータを駆動源とするため内燃機関車と比較しトルク応答性や制御性に優れるという特徴がある [?]。この高いトルク応答性を利用した運動制御に関する研究が盛んに行われている [?]。

EV は主にオンボードモータ車 (On-Board Motor EV : OBM-EV) とインホイールモータ車 (In-Wheel Motor EV : IWM-EV) に分類される。特に IWM-EV はその名の通り各車輪にモータを搭載し，各輪を独立に駆動・制御できるうえ，ドライブシャフトに起因する共振を排除できるという特徴がある。これらの特徴から，IWM-EV を対象とした運動制御に関する研究も盛んに行われており，その一つにタイヤから路面に伝達される駆動力を対象とする駆動力制御 (Driving Force Control : DFC) がある [?]。

駆動力制御はトラクション制御の一種であり，過大なスリップを抑制するためにスリップ率に上限を設ける機構 (以下，スリップ率リミッタ) が内部に存在する。これにより，通常走行時は駆動力指令値に追従しながらも，滑りやすい路面 (低μ路) においては過度な空転を抑制することができる。

各輪にかかる駆動力は，タイヤ-路面間の摩擦力として表されるが，路面摩擦係数μはタイヤのスリップ率λの実験的な関数として記述できるほか，路面状態によってその関係が異なることが一般に知られている [?]。従来の駆動力制御の多くではスリップ率リミッタを事前に決定した値に固定する手法をとっていた [?] が，スリップ率リミッタが作動した際に路面ごとに発揮可能な最大駆動力を出し続けるために，μが最大値 (μ_{peak}) となる最適スリップ率 λ_{peak} を逐次推定しスリップ率リミッタとする研究がこれまで行われてきた [?]。一例として，差分逐次最小二乗法を用いて局所的なタイヤ剛性 $D_{\mathrm{s,local}}$ を推定する手法 [?]，逐次最小二乗法を用いてタイヤブラシモデルのパラメータを推定しスリップ状態の是非を判断する手法 [?]，路面状態の画像認識結果とタイヤ剛性 $D_{\mathrm{s,local}}$ 推定結果を融合した手法 [?] などが提案されている。しかしながら，いずれも逐次最小二乗法を用いるため，推定値の収束には十分な持続的励起を要するという問題がある。また，路面状態によってはスリップ率λに対し摩擦係数μが明確なピークを持たず飽和するような場合も報告されており [?]，このような場合には推定が収束しないリスクも生じる。

また，駆動力制御によらず最適スリップ率推定を行う研究として，ニューラルネットワークを使用し，入力されたλ,μの情報から λ_{peak} を出力するような研究も存在する [?] が，シミュレーションのみで実機検証されていないほか，学習路面モデルと検証路面モデルの特性が類似し汎化性能が十分とは言えない。最適スリップ率推定に限らず，$\mu-\lambda$特性 (曲線) 全体を推定する手法も存在する [?][?][?][?] が，実車への制御応用を考慮したリアルタイム推定を行うことができているものは存在しない。

そこで本論文では，走行中に意図的なスリップ率励起を不要とし，かつピークが存在しない路面に対しても適切な



(a) FPEV-2 Kanon



(b) インホイールモータ

(a) FPEV-2 Kanon (b) In-wheel motor

図 1: 実験車両とインホイールモータ

Fig.1: Experimental vehicle and in-wheel motor

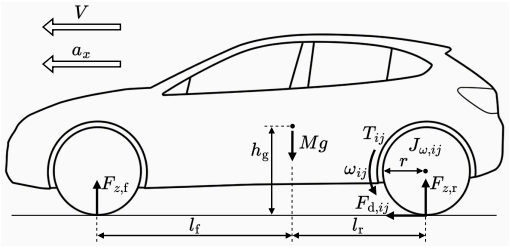


図 2: 車両モデル

Fig.2: Vehicle model

スリップリミッタを設定可能とするために，リアルタイムに $\mu-\lambda$ 曲線を推定することにより λ_{peak} を推定する手法を提案する。また，$\mu-\lambda$ 曲線の推定により μ_{peak} などタイヤ-路面特性に関わる物理量が多く得られ様々な制御応用が考えられる。本研究の $\mu-\lambda$ 曲線推定は，リアルタイム性の確保及び観測された部分的な情報から曲線全体を推定するため，機械学習を用い特定のタイヤモデルの関数やパラメータを前提とせずデータ駆動により行う。

本論文の構成を以下に示す。第 2 章では実験車両・物理モデルについて述べる。第 3 章では駆動力制御及び提案手法である機械学習モデルを用いた $\mu-\lambda$ 曲線推定および λ_{peak} 推定法について述べる。第 4 章では提案手法の有効性を，実車測定データを用いたオフライン解析結果により示す。第 5 章で結論を述べる。

2. 実験車両と物理モデル

〈2･1〉 実験車両 実験車両として著者らの研究グループが製作した 4 輪 IWM-EV「FPEV-2 Kanon」を図 1(a) に示す。搭載されている IWM を図 1(b) に示す。

〈2･2〉 車両モデル 使用する車両モデルは図 2 に示す前後運動四輪モデルである。各輪の回転方向の運動方程式は，走行抵抗を無視すると次式のように表される。

$$J_{\omega,ij}\dot{\omega}_{ij} = T_{ij} - rF_{\text{d},ij} \tag{1}$$

ここで，$J_{\omega,ij}$ は車輪の慣性モーメント，ω_{ij} は車輪角速度，T_{ij} はモータトルク，r は車輪半径，$F_{\text{d},ij}$ は接地面でタイヤに働く駆動力であり，i, j はそれぞれ前後 (f/r), 左右 (l/r) を表す。

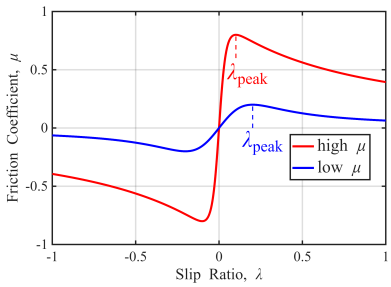


図 3: $\mu-\lambda$ 曲線

Fig.3: $\mu-\lambda$ curve

また，車両の前後方向の運動方程式は次式のようになる。

$$m\dot{V} = F_{\text{d,fl}} + F_{\text{d,fr}} + F_{\text{d,rl}} + F_{\text{d,rr}} \tag{2}$$

ここで m は車両質量，V は車両速度を表す。

一方，各輪のスリップ率 λ_{ij} は次式で定義される。

$$\lambda_{\text{ij}} = \frac{r\omega_{ij} - V}{\max(r\omega_{ij}, V, \epsilon)} \tag{3}$$

ここで ϵ は零割防止のための微小定数である。

各輪の駆動力 $F_{\text{d},ij}$ は，タイヤ-路面間の摩擦係数 μ_{ij} とタイヤにかかる垂直荷重 $F_{\text{z},ij}$ を用いて以下の式で与えられる。

$$F_{\text{d},ij} = \mu_{ij}(\lambda_{\text{ij}})F_{\text{z},ij} \tag{4}$$

μ_{ij} は，図 3 に示すように λ_{ij} の関数で表されるほか，その関係は路面状況によって変化することが知られている [?]。

また，前後加速度に基づく荷重変動を考慮すると，前後輪の荷重は以下の式で表される。

$$\begin{aligned} F_{\text{z,f}} &= \frac{l_{\text{r}}}{2(l_{\text{r}}+l_{\text{f}})}Mg - \frac{Ma_x}{2(l_{\text{r}}+l_{\text{f}})}h_{\text{g}} \\ F_{\text{z,r}} &= \frac{l_{\text{f}}}{2(l_{\text{r}}+l_{\text{f}})}Mg + \frac{Ma_x}{2(l_{\text{r}}+l_{\text{f}})}h_{\text{g}} \end{aligned} \tag{5}$$

〈2･3〉 タイヤ-路面モデル 図 3 に示す通り，$\mu-\lambda$ 曲線は非線形な形状を持つ。これに対し，実験的に関数としてフィッティングした Magic Fomula [?] というモデルが存在する。その式を以下に示す。

$$\mu_{ij} = D\sin\Big(C\arctan(B\lambda_{ij}) - E\big(B\lambda_{ij} - \arctan(B\lambda_{ij})\big)\Big) \tag{6}$$

ここで，ここで，B は Stiffness factor，C は Shape factor，D は Peak factor，E は Curvature factor と呼ばれる係数であり，この 4 つの係数により $\mu-\lambda$ 曲線をフィッティングしている. これらは直接的な物理パラメータではなく，実験データへのフィッティングによって決定される係数である。このモデルは $\mu-\lambda$ 曲線の非線形性を高精度に表現できるため，標準的なタイヤモデルとして広く用いられている。

3. 提案手法

〈3･1〉 駆動力制御 駆動力制御は，トラクション制御

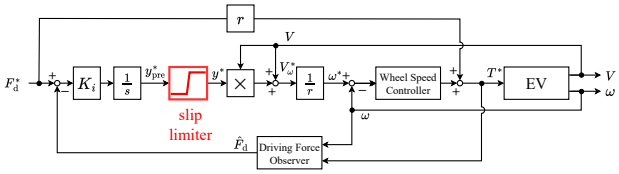


図 4: 駆動力制御 (DFC) のブロック線図
Fig.4: Block diagram of DFC

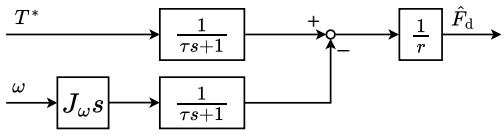


図 5: 駆動力オブザーバ (DFO)
Fig.5: Driving Force Observer : DFO

として用いられている[7]。ブロック線図を図 4 に示す。図の通りカスケード構造をとり，アウターループが駆動力オブザーバ (Driving Force Observer : DFO) に基づく駆動力制御ループとなっており，インナーループにスリップ率制御として車輪速制御ループが存在する。

DFO のブロック線図を図 5 に示す。推定される駆動力 $\hat{F}_{\mathrm{d},ij}$ は式 4 を変形し，以下の式で表される。

$$\hat{F}_{\mathrm{d},ij} = Q_{\mathrm{f}}(s)\frac{T^*_{ij} - J_{\omega,ij}\dot{\omega}_{ij}}{r} \tag{7}$$

ここで用いている $Q_{\mathrm{f}}(s) = 1/(\tau s+1)$ は時定数 τ の一次のローパスフィルタである。

一方，スリップ率は式 (3) に示すように駆動時 ($r\omega_{ij} \geq V$) と制動時 ($r\omega_{ij} < V$) で定義が異なり，制御において不都合である。そこで，スリップ率の代わりに次式で定義される操作量 y_{ij} を導入しスリップ率制御を行う。

$$y_{ij} = \frac{r\omega_{ij} - V}{V} = \frac{r\omega_{ij}}{V} - 1 \tag{8}$$

y_{ij} は制動時のスリップ率に等しく，低スリップ領域では y, λ はほぼ同じ値を取る。また，駆動力指令値に対し I 制御を行うことで指令値 y^* を生成する。一方，最大摩擦係数 μ_{peak} が小さく滑りやすい路面 (低 μ 路) においては物理的に発揮可能な最大駆動力 $F_{\mathrm{d,max}}(=\mu_{\mathrm{peak}}F_z)$ が駆動力指令値 F^*_{d} を下回る可能性があり，そのような場合スリップが過大となるリスクがある。そこで，スリップ率リミッタでスリップ率を制限することによりトラクション効果を生み出すことができる。

このスリップ率リミッタの値を，図 3 に示すような μ が最大となる（もしくは飽和する）最適スリップ率 λ_{peak} に設定することで，トラクション効果と駆動力最大化による運動性の向上を両立することができる。

〈3･2〉 提案 λ_{peak} 推定手法の概要　本研究では，走行中に観測された (λ, μ) の情報から $\mu - \lambda$ 曲線全体の形状を推定し，推定曲線から λ_{peak} を推定する。推定手法のフローチャートを¡図を作る¿に示す。曲線の推定には，多層パーセプトロン (Multi-Layer Perceptron : MLP) を用い，逐次計測された μ, λ からリアルタイムに $\mu - \lambda$ 曲線を出力する。

〈3･3〉 MLP の入力　まず，実測された駆動輪の角速度 ω_{ij} 及び車両速度 V よりスリップ率 λ_{ij} および摩擦係数 μ を計算し一定点数をバッファする。λ_{ij} は式 3 に基づき求める。μ は式 4 より DFO の出力 $\hat{F}_{\mathrm{d},ij}$ と垂直荷重推定値 $\hat{F}_{z,ij}$ から求める。$\hat{F}_{z,ij}$ は，実測された加速度 a_x を用いて式 5 に基づき計算される。

続いて，バッファされた (λ, μ) プロットを一定間隔 $\Delta\lambda$ でグリッド分けし，グリッドの内の点の mu の平均値を各グリッドの代表点とする。これにより MLP への入力サイズを固定化する。さらに，各代表点のうち最も μ が大きい値 $(\tilde{\mu}_{\max})$ で，各グリッドの代表点を正規化する。これにより学習データの μ スケールの影響を受けず様々な路面特性に対する汎化性能を発揮することができる。

最終的な入力は，n グリッドの正規化された代表値 $\boldsymbol{\mu}_{\mathrm{in,norm},k}$ に加え，部分的な観測情報からの復元の補助情報として，各グリッドに測定点が含まれるかを 0 もしくは 1 で記した $\boldsymbol{m}_k$ 及び $\tilde{\mu}_{\max,k}$ の計 $2n+1$ 次元のベクトルである。

〈3･4〉 MLP の学習　学習に用いた教師データは, MATLAB/Simulink を用いて作成した。教師曲線の作成には先述の Magic Formula モデルを利用し，様々な形状を再現した。使用した教師曲線の一覧を図¡作成する¿に示す。

〈3･5〉 設計方法　設計式やアルゴリズムを記述する。

4. 検証

シミュレーションおよび実験による検証方法を記述する。

〈4･1〉 検証条件　シミュレーション条件，実験条件，評価指標などを記述する。

〈4･2〉 シミュレーション結果　シミュレーション結果と考察を記述する。

〈4･3〉 実験結果　実験結果と考察を記述する。

5. 結論

本稿で得られた成果をまとめ，今後の課題を記述する。