EV の駆動力制御のための 機械学習を用いた$\mu-\lambda$曲線推定を伴う最適スリップ率推定の基礎検討

堀越太智*，水口時和，郡司大輔，阮平明，永井栄寿，藤本博志（東京大学）
近藤謙太郎，安元宏平，北村毅史，鷹崎悠一，北条善久（東洋電機製造株式会社）

Basic Study on Optimal Slip Ratio Estimation with Machine Learning-Based Road Surface $\mu-\lambda$ Curve Identification for Electric Vehicle Driving Force Control

Taichi Horikoshi*, Tokikazu Mizuguchi, Daisuke Gunji, Binh-Minh Nguyen, Sakahisa Nagai, Hiroshi Fujimoto
(The University of Tokyo)
Kentaro Kondo, Kohei Yasumoto, Takeshi Kitamura, Yuichi Takasaki, Yoshihisa Hojo (TOYO DENKI SEIZO K.K.)

This paper proposes a method for estimating the optimal slip ratio for electric vehicle driving force control. The proposed method estimates the tire-road $\mu-\lambda$ curve in real time from partially observed data using a machine learning model and determines the optimal slip ratio from its peak. Offline evaluation using experimental data demonstrates its effectiveness.

キーワード：電気自動車，インホイールモータ，タイヤモデル推定，スリップ率，駆動力制御，ニューラルネットワーク
(electric vehicle，in-wheel motor，tire model estimation，slip ratio，driving force control，neural network)

1. 序論

電気自動車 (Electric Vehicle : EV) は，走行時に CO_2 を排出しないという特徴[?]に加え，電動モータを駆動源とするため内燃機関車と比較しトルク応答性や制御性に優れるという特徴がある[?]。この高いトルク応答性を利用した運動制御に関する研究が盛んに行われている[?]。

EV は主にオンボードモータ車 (On-Board Motor EV : OBM-EV) とインホイールモータ車 (In-Wheel Motor EV : IWM-EV) に分類される。特に IWM-EV はその名のとおり各車輪にモータを搭載し，各輪を独立に駆動・制御できるうえ，ドライブシャフトに起因する共振を排除できるという特徴がある。これらの特徴から，IWM-EV を対象とした運動制御に関する研究も盛んに行われており，その一つにタイヤから路面に伝達される駆動力を対象とする駆動力制御 (Driving Force Control : DFC) がある[?]。

駆動力制御はトラクション制御の一種であり，過大なスリップを抑制するためにスリップ率に上限を設ける機構 (以下，スリップ率リミッタ) が内部に存在する。これにより，通常走行時は駆動力指令値に追従しながらも，滑りやすい路面 (低μ路) においては過度な空転を抑制することができる。各輪にかかる駆動力は，タイヤ-路面間の摩擦力として表されるが，路面摩擦係数μはタイヤのスリップ率λの実験的な関数として記述できるほか，路面状態によってその関係が異なることが一般に知られている[?]。従来の駆動力制御の多くではスリップ率リミッタを事前に決定した値に固定する手法をとっていた[?]が，スリップ率リミッタが作動した際に路面ごとに発揮可能な最大駆動力を出し続けるために，μが最大値 (μ_{peak}) となる最適スリップ率 λ_{peak} を逐次推定しスリップ率リミッタとする研究がこれまで行われてきた[?]。一例として，局所的なタイヤ剛性 $D_{\mathrm{s,local}}$ から λ_{peak} を推定する手法[?]，逐次最小二乗法を用いてタイヤブラシモデルのパラメータを推定しスリップ状態の是非を判断する手法[?]，路面状態の画像認識結果とタイヤ剛性 $D_{\mathrm{s,local}}$ 推定結果を融合した手法[?]などが提案されている。しかしながら，いずれも逐次最小二乗法を用いるため，推定値の収束には十分な持続的励起を要するという問題がある。また，路面状態によってはスリップ率λに対し摩擦係数μが明確なピークを持たず飽和するような場合も報告されており[?]，このような場合には推定が収束しないリスクも生じる。

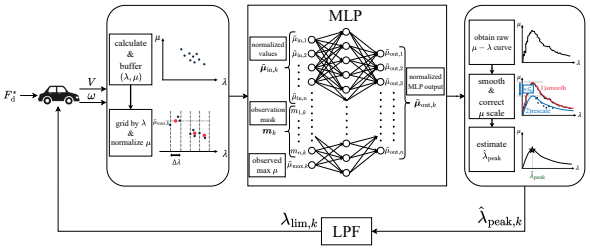


図 1: 提案手法ブロック線図
Fig.1: Block diagram of the proposal method

また，駆動力制御によらず最適スリップ率推定を行う研



(a) FPEV-2 Kanon



(b) インホイールモータ

(a) FPEV-2 Kanon (b) In-wheel motor

図 2: 実験車両とインホイールモータ

Fig.2: Experimental vehicle and in-wheel motor

究として，ニューラルネットワークを使用し，入力された λ ,μ の情報から λ_{peak} を出力するような研究も存在する [?] が，シミュレーションのみで実機検証されていないほか，学習路面モデルと検証路面モデルの特性が類似し汎化性能が十分とは言えない。最適スリップ率推定に限らず，$\mu-\lambda$ 特性 (曲線) 全体を推定する手法も存在する [?][?][?][?] が，実車への制御応用を考慮したリアルタイム推定を行うことができているものは存在しない。

そこで本論文では，走行中に意図的なスリップ率励起を不要とし，かつピークが存在しない路面に対しても適切なスリップリミッタを設定可能とするために，リアルタイムに $\mu-\lambda$ 曲線を推定することにより λ_{peak} を推定する手法を提案する。また，$\mu-\lambda$ 曲線の推定により μ_{peak} などタイヤ-路面特性に関わる物理量が多く得られ様々な制御応用が考えられる。本研究の $\mu-\lambda$ 曲線推定は，リアルタイム性の確保及び観測された部分的な情報から曲線全体を推定するため，機械学習を用い特定のタイヤモデルの関数やパラメータを前提とせずデータ駆動により行う。

本論文の構成を以下に示す。第 2 章では実験車両・物理モデルについて述べる。第 3 章では駆動力制御及び提案手法である機械学習モデルを用いた $\mu-\lambda$ 曲線推定および λ_{peak} 推定法について述べる。第 4 章では提案手法の有効性を，実車測定データにおける駆動力の比較により示す。第 5 章で結論を述べる。

2. 実験車両と物理モデル

〈2･1〉 実験車両 実験車両として著者らの研究グループが製作した 4 輪 IWM-EV「FPEV-2 Kanon」を図 2(a) に示す。搭載されている IWM を図 2(b) に示す。

〈2･2〉 車両モデル 使用する車両モデルは図 3 に示す前後運動四輪モデルである。各輪の回転方向の運動方程式は，走行抵抗を無視すると次式のように表される。

$$J_{\omega,ij}\dot{\omega}_{ij} = T_{ij} - rF_{\text{d},ij} \tag{1}$$

ここで，$J_{\omega,ij}$ は車輪の慣性モーメント，ω_{ij} は車輪角速度，T_{ij} はモータトルク，r は車輪半径，$F_{\text{d},ij}$ は接地面でタイヤ

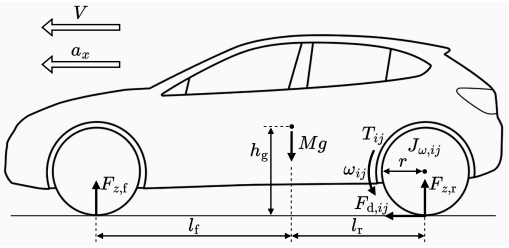


図 3: 車両モデル

Fig.3: Vehicle model

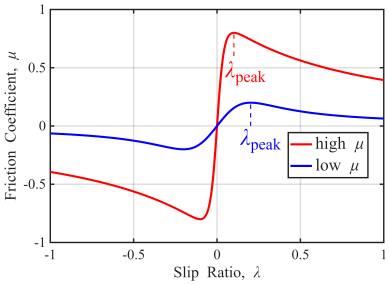


図 4: $\mu-\lambda$ 曲線

Fig.4: $\mu-\lambda$ curve

に働く駆動力であり，i, j はそれぞれ前後 (f/r), 左右 (l/r) を表す。

また，車両の前後方向の運動方程式は次式のようになる。

$$m\dot{V} = F_{\text{d,fl}} + F_{\text{d,fr}} + F_{\text{d,rl}} + F_{\text{d,rr}} \tag{2}$$

ここで m は車両質量，V は車両速度を表す。

一方，各輪のスリップ率 λ_{ij} は次式で定義される。

$$\lambda_{\text{ij}} = \frac{r\omega_{ij} - V}{\max(r\omega_{ij}, V, \epsilon)} \tag{3}$$

ここで ϵ は零割防止のための微小定数である。

各輪の駆動力 $F_{\text{d},ij}$ は，タイヤ-路面間の摩擦係数 μ_{ij} とタイヤにかかる垂直荷重 $F_{\text{z},ij}$ を用いて以下の式で与えられる。

$$F_{\text{d},ij} = \mu_{ij}(\lambda_{\text{ij}})F_{\text{z},ij} \tag{4}$$

μ_{ij} は，図 4 に示すように λ_{ij} の関数で表されるほか，その関係は路面状況によって変化することが知られている [?]。

また，前後加速度に基づく荷重変動を考慮すると，前後輪の荷重は以下の式で表される。

$$\begin{aligned} F_{\text{z,f}} &= \frac{l_{\text{r}}}{2(l_{\text{r}}+l_{\text{f}})}Mg - \frac{Ma_x}{2(l_{\text{r}}+l_{\text{f}})}h_{\text{g}} \\ F_{\text{z,r}} &= \frac{l_{\text{f}}}{2(l_{\text{r}}+l_{\text{f}})}Mg + \frac{Ma_x}{2(l_{\text{r}}+l_{\text{f}})}h_{\text{g}} \end{aligned} \tag{5}$$

〈2･3〉 タイヤ-路面モデル 図 4 に示すとおり，$\mu-\lambda$ 曲線は非線形な形状を持つ。これに対し，実験的に関数としてフィッティングした Magic Fomula [?] というモデルが存在する。その式を以下に示す。

$$\mu_{ij} = D\sin\Big(C\arctan(B\lambda_{ij}) - E\big(B\lambda_{ij} - \arctan(B\lambda_{ij})\big)\Big) \tag{6}$$

ここで，ここで，B は Stiffness factor，C は Shape factor，D は Peak factor，E は Curvature factor と呼ばれる係数であり，

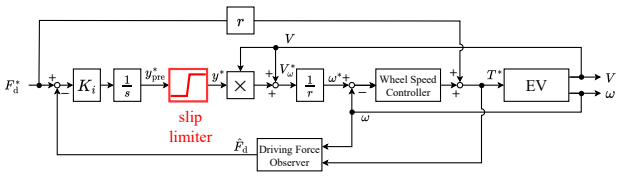


図 5: 駆動力制御 (DFC) のブロック線図
Fig.5: Block diagram of DFC

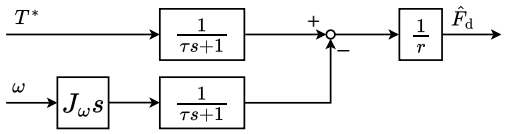


図 6: 駆動力オブザーバ (DFO)
Fig.6: Driving Force Observer : DFO

この 4 つの係数により $\mu-\lambda$ 曲線をフィッティングしている. これらは直接的な物理パラメータではなく，実験データへのフィッティングによって決定される係数である。このモデルは $\mu-\lambda$ 曲線の非線形性を高精度に表現できるため，標準的なタイヤモデルとして広く用いられている。

3. 提案手法

〈3･1〉 駆動力制御 駆動力制御は，トラクション制御として用いられている [?]。ブロック線図を図 5 に示す。図のとおりカスケード構造をとり，アウターループが駆動力オブザーバ (Driving Force Observer : DFO) に基づく駆動力制御ループとなっており，インナーループにスリップ率制御として車輪速制御ループが存在する。

DFO のブロック線図を図 6 に示す。推定される駆動力 $\hat{F}_{\mathrm{d},ij}$ は式 4 を変形し，以下の式で表される。

$$\hat{F}_{\mathrm{d},ij} = Q_{\mathrm{f}}(s)\frac{T_{ij}^* - J_{\omega,ij}\dot{\omega}_{ij}}{r} \tag{7}$$

ここで用いている $Q_{\mathrm{f}}(s) = 1/(\tau s+1)$ は時定数 τ の一次のローパスフィルタである。

一方，スリップ率は式 (3) に示すように駆動時 ($r\omega_{ij} \geq V$) と制動時 ($r\omega_{ij} < V$) で定義が異なり，制御において不都合である。そこで，スリップ率の代わりに次式で定義される操作量 y_{ij} を導入しスリップ率制御を行う。

$$y_{ij} = \frac{r\omega_{ij} - V}{V} = \frac{r\omega_{ij}}{V} - 1 \tag{8}$$

y_{ij} は制動時のスリップ率に等しく，低スリップ領域では y, λ はほぼ同じ値を取る。また，駆動力指令値に対し I 制御を行うことで指令値 y^* を生成する。一方，最大摩擦係数 μ_{peak} が小さく滑りやすい路面 (低 μ 路) においては物理的に発揮可能な最大駆動力 $F_{\mathrm{d,max}}(=\mu_{\mathrm{peak}}F_z)$ が駆動力指令値 F_{d}^* を下回る可能性があり，そのような場合スリップが過大となるリスクがある。そこで，スリップ率リミッタでスリップ率を制限することによりトラクション効果を生み出すことができる。

このスリップ率リミッタの値を，図 4 に示すような μ が最大となる（もしくは飽和する）最適スリップ率 λ_{peak} に設定することで，トラクション効果と駆動力最大化による運動性の向上を両立することができる。

〈3･2〉 提案 λ_{peak} 推定手法の概要 本研究では，走行中に観測された (λ,μ) の情報から $\mu-\lambda$ 曲線全体の形状を推定し，推定曲線から λ_{peak} を推定する。推定手法のフローチャートは図 1 に示したとおりである。曲線の推定には，多層パーセプトロン (Multi-Layer Perceptron : MLP) を用い，逐次計測された μ,λ からリアルタイムに $\mu-\lambda$ 曲線を出力する。

〈3･3〉 MLP の構造・学習条件 本研究では，$\mu-\lambda$ 曲線を逐次推定するため，3 層の隠れ層を有する全結合型多層パーセプトロンを用いた。後述するように，入力層の次元数は $2n+1$，出力層の次元数は n であり，各隠れ層のユニット数は 128 とした。各隠れ層の活性化関数には ReLU 関数を用い，出力層は線形活性化関数を用いた。学習には Adam を用い，学習率を 1.0×10^{-4}，ミニバッチサイズを 1024，学習エポック数を 1000 とした。

〈3･4〉 MLP の入力 まず，実測された駆動輪の角速度 ω_{ij} 及び車両速度 V よりスリップ率 λ_{ij} および摩擦係数 μ を計算し一定点数をバッファする。λ_{ij} は式 3 に基づき求める。μ は式 4 より DFO の出力 $\hat{F}_{\mathrm{d},ij}$ と垂直荷重推定値 $\hat{F}_{z,ij}$ から求める。$\hat{F}_{z,ij}$ は，実測された加速度 a_x を用いて式 5 に基づき計算される。

続いて，バッファされた (λ,μ) プロットを一定間隔 $\Delta\lambda$ でグリッド分けし，グリッドの内の点の μ の平均値を各グリッドの代表点とする。これにより MLP への入力サイズを固定化する。さらに，各代表点のうち最も μ が大きい値 $(\tilde{\mu}_{\max})$ で，各グリッドの代表点を正規化する。これにより学習データの μ スケールの影響を受けず様々な路面特性に対する汎化性能を発揮することができる。

最終的な入力は，各時刻ステップ k に対し n グリッドの正規化された代表値 $\tilde{\boldsymbol{\mu}}_{\mathrm{in},k}$ に加え，部分的な観測情報からの復元の補助情報として，各グリッドに測定点が含まれるかを 0 もしくは 1 で記した $\boldsymbol{m}_k$ 及び $\tilde{\mu}_{\max,k}$ の計 $2n+1$ 次元のベクトルである。本稿では，対象とするスリップ率の範囲は現実的なスリップ率を考え $0 \leq \lambda \leq 0.5$ とし，$n = 501$ とした。

〈3･5〉 MLP の学習 学習に用いた教師データは, MATLAB/Simulink を用いて作成した。教師曲線の作成には先述の Magic Formula モデルを利用し，μ により形状が決定されないよう，μ_{peak} に影響を与える係数 D を固定し曲線の形状を様々設定し，その後に D を $0.2, 0.3, 0.4, 0.5$ に変更し，計 72 種類の教師路面データを作成した。使用した教師曲線の一覧を図 7 に示す。

また，学習用の入力データには各路面での走行を模擬し

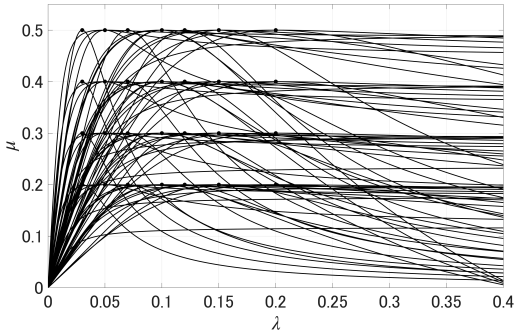


図 7: 学習 $\mu-\lambda$ 曲線
Fig.7: Learned $\mu-\lambda$ curves

たシミュレーション結果を用いた。実装時に走行中に得られるのは部分的な $\mu-\lambda$ プロットであるため，学習段階でも部分的な観測情報を再現する必要がある。そこで，シミュレーション上で $0 \le \lambda \le 0.6$ の範囲で指令値を三角波状に与えたスリップ率制御を行い十分広い範囲の $\mu-\lambda$ 特性を取得したのち，ランダムシードを用いてランダムな範囲で入力を与えた。

MLP の学習モデルの損失関数は次式に示すとおりである。

$$L_{\text{Total}} = 0.1L_{\text{Data}} + 1.0L_{\text{Input}} \tag{9}$$

L_{Data} と L_{Input} はそれぞれ教師データ，入力データとの MSE であり，いずれもグリッド化しグリッド内の平均をとった値との MSE を計算している。また，入力データは内部に測定点が 1 点以上存在するグリッドのみを対象としている。L_{Data} に対し L_{Input} の重みを十分大きくすることで，観測点が存在するグリッドでは十分観測点に近い値を出力しながらも，観測点が存在しない範囲では教師データによる外挿によって自然な $\mu-\lambda$ 曲線を出力することができる。

〈3･6〉 MLP の出力　MLP の出力は，各スリップ率グリッドにおける正規化された摩擦係数推定値からなる n 次元ベクトル $\tilde{\boldsymbol{\mu}}_{\text{out},k}$ である。ただし，MLP は各グリッド点の推定値を独立して出力しているため，$\mu-\lambda$ 平面上では振動を含む。この振動を低減するため，多項式次数を 3, 窓幅を 51 とする Savitzky-Golay フィルタ [?] を適用する。

続いて正規化された出力を観測点のスケールに補正する。スケール補正ゲインを $G_{\mu,k}$ とし，$\tilde{\boldsymbol{\mu}}_{\text{out},k}$ に $G_{\mu,k}$ をかけた値と正規化前の観測値 $\boldsymbol{\mu}_{\text{in},k}$ との二乗誤差の総和を最小にするように設定すると，$G_{\mu,k}$ は以下の数式で与えられる。

$$G_{\mu,k} = \frac{\sum_{i:m_{i,k}=1} \tilde{\mu}_{\text{out},i,k}\,\mu_{\text{in},i,k}}{\sum_{i:m_{i,k}=1} \tilde{\mu}^2_{\text{out},i,k}} \tag{10}$$

ここで，$i \in \{1,\ldots,n\}$ はグリッド番号を表し，$m_{i,k}=1$ は時刻 k においてグリッド i に観測点が存在することを表す。

以上の処理により，逐次 $\mu-\lambda$ 曲線をノンパラメトリックに推定することができる。

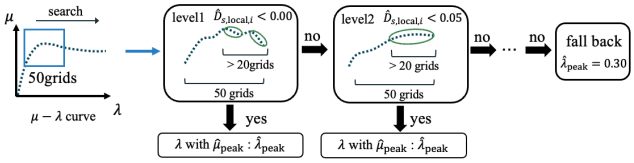


図 8: $\hat{\lambda}_{\text{peak}}$ 推定アルゴリズム
Fig.8: $\hat{\lambda}_{\text{peak}}$ estimation algorithm

〈3･7〉 λ_{peak} 推定　得られた推定 $\mu-\lambda$ 曲線から，λ_{peak} の推定を行う。推定のフローチャートを図 8 に示す。まず，各グリッド i における $\mu-\lambda$ 曲線の傾き $\hat{D}_{\text{s,local},i}$ を次式により推定する。

$$\hat{D}_{\text{s,local},i} = \frac{\mu_{i+1} - \mu_{i-1}}{2\Delta\lambda}. \tag{11}$$

ここで $\Delta\lambda$ はグリッド幅であるほか，両端のグリッドでは中心差分ではなく片側差分により $\hat{D}_{\text{s,local},i}$ を求める。

次に，連続する 50 グリッドの集合について，そのうち 20 グリッドで $\hat{D}_{\text{s,local},i} < 0$ となる λ が最小の集合を決定し，その中で最も大きな μ をピーク摩擦係数 $\hat{\mu}_{\text{peak}}$，その時の λ を最適スリップ率 $\hat{\lambda}_{\text{peak}}$ とする。対象とする λ の範囲にそのような条件を満たす集合が存在しない場合，判定閾値を $\hat{D}_{\text{s,local},i} < 0.05$ とし同様の探索を行う。それでも条件を満たさない場合は $\hat{D}_{\text{s,local},i} < 0.10$ とし，これ以上見つからない場合は，$\hat{\lambda}_{\text{peak}} = 0.30$ とし推定を打ち切る。

これにより，ピークが明確に存在しない場合でも μ が飽和するスリップ率を最適スリップ率として推定できるほか，推定 $\mu-\lambda$ 曲線に振動が残っていてもロバストなピーク点判定を行うことができる。

4. 検証

シミュレーションおよび実験による検証方法を記述する。

〈4･1〉 検証条件　シミュレーション条件，実験条件，評価指標などを記述する。

〈4･2〉 シミュレーション結果　シミュレーション結果と考察を記述する。

〈4･3〉 実験結果　実験結果と考察を記述する。

5. 結論

本稿で得られた成果をまとめ，今後の課題を記述する。